



RAPPORT ACADEMIQUE

DEEP LEARNING

Projet final integrateur

MLP CNN RNN LSTM GRU Seq2Seq

Nom	Kenza Ezzahed
Filiere	AI & Data Science
Groupe	1
Site	Moulay Youssef
Ecole	EMSI Casablanca
Module	Deep Learning
Annee universitaire	2025–2026

Ce rapport presente les resultats experimentaux obtenus sur les trois notebooks du projet et leur analyse academique, sans inclure le code source.

CONTENU DU PROJET

- I** Classification tabulaire (Breast Cancer Wisconsin) avec un MLP
- II** Classification d'images (CIFAR-10) avec un CNN
- III** Traduction automatique anglais-allemand (Multi30k) avec RNN, LSTM, GRU et Seq2Seq

Remerciements

Je remercie l'ensemble du corps professoral de l'EMSI Casablanca pour la qualite de la formation dispensee en intelligence artificielle et science des donnees, et en particulier l'enseignant du module Deep Learning pour l'encadrement et les orientations pedagogiques apportees sur les reseaux de neurones modernes durant ce semestre.

Je remercie egalement ma famille et mes proches pour leur soutien durant cette formation, ainsi que mes camarades de groupe avec qui j'ai pu discuter de certains choix d'hyperparametres pendant les seances de travaux pratiques.

Resume

Ce projet explore trois familles d'architectures neuronales sur trois taches distinctes : la classification tabulaire du cancer du sein avec un perceptron multicouche (MLP), la reconnaissance d'images CIFAR-10 avec un reseau convolutif (CNN), et la traduction automatique anglais-allemand avec un systeme Seq2Seq comparant RNN, LSTM et GRU. L'objectif n'est pas seulement de mesurer une performance finale mais de comprendre, pour chaque type de donnees, pourquoi une architecture donnee se comporte mieux qu'une autre.

Les resultats confirment globalement l'intuition theorique : le MLP est tres performant sur des donnees tabulaires normalisees (97,37% d'accuracy test), le CNN domine largement une baseline MLP sur des images (79,94% contre 45,10%) avec moins de parametres, et le GRU offre le meilleur compromis perplexite/temps d'entrainement parmi les architectures recurrentes testees (34,56 de perplexite finale). Quelques resultats moins attendus – notamment un ecart entre l'accuracy du modele principal et celle obtenue lors du test d'initialisation isole – sont egalement discutes, car ils rappellent que des comparaisons issues d'executions distinctes ne sont pas strictement comparables sans fixation de la graine aleatoire.

Mots-cles : Deep Learning, PyTorch, MLP, CNN, RNN, LSTM, GRU, Seq2Seq, CIFAR-10, Multi30k, classification, traduction automatique.

Abstract

This report studies three families of neural architectures on three distinct tasks : tabular breast-cancer classification with a multilayer perceptron, CIFAR-10 image classification with a convolutional network, and English-to-German machine translation with a Seq2Seq system comparing RNN, LSTM and GRU cells. Beyond final scores, the goal is to explain, for each data modality, why one architecture outperforms another.

Results align with theoretical expectations : the MLP performs strongly on normalized tabular data (97.37% test accuracy), the CNN clearly outperforms an MLP baseline on images (79.94% vs. 45.10%) while using fewer parameters, and the GRU yields the best perplexity/training-time trade-off among the recurrent architectures tested (34.56 final perplexity). A few less expected observations – in particular a gap between the main model’s accuracy and the isolated initialization-comparison run – are discussed as well, since they are a useful reminder that results from separate runs without a fixed random seed are not strictly comparable.

Table des matières

1	Introduction generale	6
2	Methodologie experimentale	7
3	Partie I – MLP pour la classification du cancer du sein	8
3.1	Contexte et donnees	8
3.2	Architecture et entrainement	8
3.3	Resultats experimentaux	8
3.4	Analyse de l’initialisation	9
3.5	Interpretation	10
4	Partie II – CNN pour la vision par ordinateur sur CIFAR-10	11
4.1	Contexte	11
4.2	Architecture CNN et baseline MLP	11
4.3	Courbes d’entrainement	12
4.4	Evaluation finale	12
4.5	Interpretation	13
5	Partie III – RNN, LSTM, GRU et Seq2Seq	15
5.1	Contexte NLP	15
5.2	Problematique du gradient et clipping	15
5.3	Comparaison RNN, LSTM et GRU	16
5.4	Decodage glouton, beam search et BLEU	16
5.5	Interpretation	17
6	Synthese comparative des architectures	19
7	Limites, ameliorations et perspectives	20
7.1	Limites observees	20
7.2	Ameliorations possibles	20
7.3	Perspectives academiques	20
8	Conclusion generale	21

Bibliographie indicative

22

1. Introduction generale

Le Deep Learning permet d'apprendre automatiquement des representations a partir de donnees variees – tableaux numeriques, images, textes ou sequences – plutot que de concevoir des features a la main. Ce qui m'a interesse dans ce projet n'est pas tant la performance finale de chaque modele que la justification du choix d'architecture : pourquoi un MLP suffit-il pour des donnees tabulaires alors qu'il s'effondre presque sur des images, et pourquoi des cellules a portes comme le LSTM ou le GRU sont-elles necessaires sur des sequences alors qu'un RNN simple suffirait en theorie ?

Le rapport est organise en trois experimentations independantes mais comparables dans leur methodologie : un MLP sur des donnees medicales tabulaires, un CNN sur CIFAR-10, et un systeme encodeur-decodeur recurrent sur Multi30k.

Objectifs du projet

- Comprendre le fonctionnement interne d'un MLP, d'un CNN et d'un modele recurrent.
- Comparer les architectures selon la nature des donnees traitees (tabulaire, spatiale, sequentielle).
- Analyser les courbes de perte, les performances finales et les erreurs de prediction – pas seulement les rapporter, mais identifier ce qu'elles signifient sur le comportement du modele.
- Justifier les choix d'architecture effectues et proposer des ameliorations concretes, plutot que generiques.

Organisation du rapport

Chaque partie suit la meme trame : contexte des donnees, architecture et entraînement, resultats, puis interpretation critique. J'ai volontairement garde les memes sections pour les trois parties afin de pouvoir comparer directement, en chapitre 6, la maniere dont chaque famille de modeles echoue ou reussit.

2. Methodologie experimentale

Les trois experimentations ont ete realisees avec PyTorch, dans trois notebooks separes. Les donnees ont chacune ete separees en ensembles d'entrainement, de validation et de test. La fonction de perte est la cross-entropy pour les deux taches de classification, et une cross-entropy masquee (qui ignore les positions de padding) pour la generation de sequences en Partie III.

Partie	Donnees	Architecture principale	Metriques
I	Breast Cancer Wisconsin	MLP	Accuracy, precision, recall, F1-score
II	CIFAR-10	CNN inspire de LeNet	Accuracy, F1-score, matrice de confusion
III	Multi30k allemand anglais	Seq2Seq (RNN, LSTM, GRU)	Perplexite, BLEU-1

TABLE 2.1 – Synthese des trois experimentations.

La logique experimentale est commune aux trois parties : preparation des donnees, definition du modele, entrainement, selection du meilleur modele (sur validation, et non sur la derniere epoque), evaluation finale, puis interpretation des resultats. Ce choix de selectionner le checkpoint sur la validation plutot que sur la derniere epoque s'est avere important, en particulier pour le MLP de la Partie I ou un surapprentissage apparait clairement (cf. §3.3).

3. Partie I – MLP pour la classification du cancer du sein

3.1 Contexte et donnees

Le jeu de donnees Breast Cancer Wisconsin contient 569 observations decrites par 30 caracteristiques numeriques issues de l'analyse d'images de cellules tumorales (rayon, texture, perimetre, etc.), pour une classification binaire (benin/malin). Ces variables sont continues, de plage comparable apres normalisation, et n'ont aucune structure spatiale ou temporelle entre elles – c'est precisement ce type de donnees pour lequel un MLP est l'architecture la plus naturelle, sans qu'il soit necessaire d'imposer un biais inductif particulier comme le ferait un CNN sur une image.

Element	Valeur
Nombre total d'observations	569
Nombre de caracteristiques	30
Entrainement	364 observations
Validation	91 observations
Test	114 observations
Type de tache	Classification binaire

TABLE 3.1 – Repartition des donnees Breast Cancer Wisconsin.

3.2 Architecture et entraînement

Le modele prend en entree les 30 variables, suivies de deux couches cachees (64 puis 32 neurones, activation ReLU) et d'une couche de sortie a 2 classes. L'optimiseur est Adam (taux d'apprentissage 0,001), avec une cross-entropy comme fonction de perte, sur 50 epoques.

J'ai retenu Adam plutot qu'un simple SGD car le jeu de donnees est petit (364 exemples d'entraînement) : Adam adapte le taux d'apprentissage par parametre, ce qui accelere la convergence sur peu de donnees sans necessiter un reglage fin du learning rate de depart.

3.3 Resultats experimentaux

La perte d'entraînement diminue de maniere monotone, ce qui est attendu. La perte de validation en revanche baisse jusqu'a environ l'epoque 10–12, puis remonte progressivement jusqu'a la fin de l'entraînement – un signal classique de surapprentissage : le modele continue a reduire l'erreur sur les exemples d'entraînement qu'il a deja vus, mais generalise moins bien sur des exemples nouveaux. C'est la raison pour laquelle le modele retenu pour l'evaluation finale est celui qui maximise l'accuracy de validation (0,9670), et non le modele obtenu a la 50^e epoque.

Sur le jeu de test, ce modele atteint une accuracy de 97,37%, avec un F1-score de 97,87%.

Parametre	Choix experimental
Taille d'entree	30 variables numeriques
Couches cachees	64 neurones puis 32 neurones
Activation	ReLU
Sortie	2 classes
Optimiseur	Adam
Fonction de perte	Cross-entropy
Nombre d'epoques	50

TABLE 3.2 – Hyperparametres du MLP.




FIGURE 3.1 – Courbe de perte du MLP : entraînement vs validation.

La matrice de confusion $\begin{pmatrix} 42 & 1 \\ 2 & 69 \end{pmatrix}$ montre seulement 3 erreurs sur 114 exemples de test : 1 faux positif et 2 faux négatifs. Dans un contexte medical, les 2 faux négatifs (cas malins prédits comme bénins) seraient les erreurs les plus coûteuses en pratique ; le rappel de 97,18% reste très bon mais n'est pas parfait, ce qui justifierait en situation réelle un seuil de décision asymétrique plutôt qu'un seuil à 0,5 par défaut.

3.4 Analyse de l'initialisation

Trois stratégies d'initialisation des poids ont été comparées indépendamment du modèle principal ci-dessus : gaussienne, constante et Xavier.

gaussienne	accuracy: 0.9825 f1: 0.9859
constante	accuracy: 0.9474 f1: 0.9577
xavier	accuracy: 0.9649 f1: 0.9718

FIGURE 3.2 – Sortie brute de la comparaison des trois initialisations.

Metrique	Valeur
Accuracy test	97,37 %
Precision	98,57 %
Recall	97,18 %
F1-score	97,87 %
Matrice de confusion	$\begin{bmatrix} 42 & 1 \\ 2 & 69 \end{bmatrix}$

TABLE 3.3 – Metriques finales du MLP sur le jeu de test.

Initialisation	Accuracy	F1-score	Interpretation
Gaussienne	98,25 %	98,59 %	Meilleur resultat observe dans cette comparaison
Constante	94,74 %	95,77 %	Moins efficace – risque de symetrie entre neurones
Xavier	96,49 %	97,18 %	Stable mais legerement inferieure ici

TABLE 3.4 – Comparaison des strategies d’initialisation.

Discussion. Ce resultat merite une remarque : l’initialisation gaussienne testee ici atteint 98,25%, soit un score superieur a celui du modele principal entraine en §3.3 (97,37%), alors que les deux experiences portent sur le meme jeu de test. Ce n’est pas une contradiction – ce sont deux executions distinctes, avec un tirage aleatoire des poids et potentiellement un ordre de batches differents – mais cela illustre une limite methodologique reelle : sur un jeu de test de seulement 114 exemples, une difference de 1 a 2 erreurs suffit a deplacer l’accuracy de 1 point, et conclure qu’une initialisation est “meilleure” qu’une autre sur la base d’une seule execution est statistiquement fragile. Une comparaison plus rigoureuse necessiterait de moyennner sur plusieurs graines aleatoires (*seeds*) pour chaque initialisation. Le resultat qualitatif reste neanmoins coherent avec la theorie : l’initialisation constante brise la symetrie de descente de gradient (tous les neurones d’une meme couche recoivent le meme gradient au depart) et est donc structurellement defavorisee, ce qui se confirme ici par son score le plus bas des trois.

3.5 Interpretation

Le MLP est adapte a ce probleme parce que les variables sont tabulaires, normalisees, et que l’ordre des colonnes n’a pas de sens spatial ou temporel a exploiter – contrairement aux pixels d’une image. Les deux classes sont par ailleurs relativement bien separables dans cet espace de features, ce qui explique le score eleve obtenu malgre un modele simple a deux couches cachees. La remontee de la perte de validation observee en §3.3 reste neanmoins le point a surveiller : sur un jeu de donnees aussi petit (364 exemples d’entrainement), 50 epoques sans regularisation explicite (dropout, weight decay) laissent une marge reelle de surapprentissage, meme si le score final reste tres bon grace a la selection du meilleur checkpoint sur validation.

4. Partie II – CNN pour la vision par ordinateur sur CIFAR-10

4.1 Contexte

CIFAR-10 contient 10 classes d’objets, en images 32×32 RGB. A la difference des donnees tabulaires de la Partie I, les pixels voisins sont fortement correles : c’est cette structure spatiale locale (bords, textures, formes) qu’un MLP applique a une image aplatie ignore totalement, puisqu’il traite chaque pixel comme une variable independante des autres.

Element	Valeur
Dataset	CIFAR-10
Nombre de classes	10
Format des images	32×32 RGB
Train	40 000 images
Validation	10 000 images
Test	10 000 images
Augmentation	Flip horizontal et recadrage aleatoire

TABLE 4.1 – Repartition et pretraitement des donnees CIFAR-10.



FIGURE 4.1 – Exemples d’images CIFAR-10 apres preparation des donnees.

4.2 Architecture CNN et baseline MLP

Une baseline MLP a d’abord ete entrainee sur les images aplaties (vecteur de 3 072 valeurs), pour quantifier objectivement la perte de performance liee a l’absence de structure spatiale. Le CNN utilise ensuite trois blocs convolutifs (convolution, batch normalization, ReLU, pooling), une convolution 1×1 pour la transformation des canaux, puis un classificateur dense.

Le point notable ici n’est pas seulement que le CNN est meilleur, mais qu’il l’est avec un nombre de parametres environ 2,7 fois plus faible. Cela tient au partage des poids : un meme filtre convolutif est applique a toutes les positions de l’image, alors que la couche dense de la baseline MLP doit apprendre une connexion separee pour chacun des 3 072 pixels d’entree.

Modele	Parametres	Principe
MLP baseline	1 707 274	Image aplatie en vecteur de 3 072 valeurs
CNN	624 970	Filtres locaux, pooling, extraction hiérarchique de features

TABLE 4.2 – Comparaison du nombre de parametres entre la baseline MLP et le CNN.

4.3 Courbes d’entrainement




FIGURE 4.2 – Courbes de perte et accuracy de la baseline MLP sur CIFAR-10.

La baseline MLP progresse lentement et plafonne autour de 45–47% d’accuracy de validation : sans biais inductif spatial, le modele doit en quelque sorte “redécouvrir” depuis zero que des pixels voisins sont correles, ce qui demande beaucoup plus de capacite et de donnees qu’il n’en a ici.




FIGURE 4.3 – Courbes de perte et accuracy du CNN sur CIFAR-10.

Le CNN converge nettement plus vite et atteint un plateau bien plus haut. Les courbes train/val restent proches l’une de l’autre tout au long de l’entrainement, ce qui indique une generalisation correcte (peu d’ecart train-val), contrairement au MLP de la Partie I dont la perte de validation se degradait nettement apres quelques epoques.

4.4 Evaluation finale

En regardant la matrice de confusion ligne par ligne plutot que les F1-scores seuls : sur les 1 000 images de la classe *cat*, 167 sont predites *dog* – c’est la plus grande case hors-diagonale de toute la matrice – alors que la confusion inverse (*dog* predit *cat*) ne concerne que 148 images. Le modele est donc legerement plus enclin a confondre un chat avec un chien qu’inversement,

Modele	Accuracy test	Observation
MLP baseline	45,10 %	Performance limitee par la perte de structure spatiale
CNN	79,94 %	Net gain grace aux convolutions et au pooling

TABLE 4.3 – Accuracy de test, baseline MLP vs CNN.

Test Accuracy – MLP : 45.10%
 Test Accuracy – CNN : 79.94%

=== Classification Report (CNN) ===				
	precision	recall	f1-score	support
airplane	0.79	0.84	0.82	1000
automobile	0.90	0.92	0.91	1000
bird	0.72	0.69	0.70	1000
cat	0.63	0.61	0.62	1000
deer	0.77	0.78	0.78	1000
dog	0.71	0.71	0.71	1000
frog	0.80	0.88	0.84	1000
horse	0.88	0.81	0.84	1000
ship	0.90	0.89	0.90	1000
truck	0.89	0.87	0.88	1000
accuracy			0.80	10000
macro avg	0.80	0.80	0.80	10000
weighted avg	0.80	0.80	0.80	10000

FIGURE 4.4 – Rapport de classification complet (precision/recall/F1) du CNN sur CIFAR-10.

ce qui est coherent avec le fait que la classe *cat* a le F1 le plus bas du tableau. On observe egalement un groupe de confusions plus diffus entre *bird*, *deer* et *frog* (40 a 74 images echangees entre paires), probablement lie a des arriere-plans naturels similaires (vegetation, exterieur) plutot qu'a une ressemblance directe entre les animaux eux-memes.

4.5 Interpretation

L'ecart entre le MLP et le CNN est de 34,84 points d'accuracy, obtenu avec environ 63% de parametres en moins pour le CNN. Cela illustre concretement ce que la theorie appelle un "biais inductif" : en imposant que chaque filtre soit applique localement et de la meme maniere partout dans l'image, le CNN n'a pas besoin d'apprendre independamment qu'un bord vertical en haut a gauche de l'image ressemble a un bord vertical en bas a droite – c'est une hypothese integree dans l'architecture elle-meme, alors que le MLP doit la retrouver implicitement a partir des donnees, ce qui est beaucoup plus couteux en capacite et en exemples d'entrainement.




FIGURE 4.5 – Matrice de confusion du CNN sur le jeu de test CIFAR-10.

Classe	F1-score	Commentaire
automobile	0,91	Tres bonne reconnaissance
ship	0,90	Classe visuellement distinctive
truck	0,88	Bonne separation globale
cat	0,62	Classe la plus difficile
dog	0,71	Confusion frequente avec cat

TABLE 4.4 – F1-score par classe (extrait), CNN sur CIFAR-10.

Aspect	MLP	CNN
Representation	Vecteur aplati	Cartes de caracteristiques spatiales
Nombre de parametres	Plus eleve	Plus faible
Accuracy test	45,10 %	79,94 %
Generalisation	Limitee	Meilleure
Adaptation aux images	Faible	Forte

TABLE 4.5 – Synthese MLP vs CNN sur CIFAR-10.

5. Partie III – RNN, LSTM, GRU et Seq2Seq

5.1 Contexte NLP

La traduction automatique anglais-allemand sur Multi30k pose un probleme different des deux parties precedentes : les entrees sont des sequences ordonnees, ou le mot suivant depend du contexte deja genere. Un systeme Seq2Seq encodeur-decodeur a ete utilise : l’encodeur lit la phrase source et produit un contexte, le decodeur genere ensuite la phrase cible mot par mot. Trois cellules recurrentes ont ete comparees dans ce role : RNN simple, LSTM et GRU.

Element	Valeur
Dataset	Multi30k anglais-allemand
Paires d’entrainement	29 000
Paires de validation	1 014
Vocabulaire source	5 000 mots
Vocabulaire cible	5 000 mots
Longueur maximale	20 tokens
Embeddings	128 dimensions
Dimension cachee	256
Nombre de couches	2
Dropout	0,3

TABLE 5.1 – Configuration du systeme Seq2Seq.

5.2 Problematique du gradient et clipping

L’entrainement d’un reseau recurrent se fait par retropropagation a travers le temps : le gradient de la perte finale est propage en arriere a travers chaque pas de temps de la sequence. Pour des sequences un peu longues, ce gradient peut s’amplifier d’un pas a l’autre et finir par exploser. Le gradient clipping borne la norme globale du gradient avant la mise a jour des poids.

Dans l’experience, la norme maximale observee sans clipping atteint 2,93, contre 1,00 avec clipping actif – soit un pic presque 3 fois plus eleve que le seuil fixe. Concretement, sans cette limite, le mini-batch correspondant a ce pic aurait produit une mise a jour des poids proportionnellement plus violente que les mini-batches voisins, ce qui peut suffire a faire diverger l’entrainement meme si les batches suivants redeviennent normaux.




FIGURE 5.1 – Effet du gradient clipping sur la norme du gradient.




FIGURE 5.2 – Courbes de perte (train/validation) pour le RNN, le LSTM et le GRU.

5.3 Comparaison RNN, LSTM et GRU

Le saut de perplexité entre le RNN simple (153,84) et le LSTM (37,30) est le résultat le plus frappant des trois : un facteur d'environ 4 sur une seule métrique, pour un modèle qui n'a que 46% de paramètres en plus. Cela confirme que le problème du RNN simple n'était pas un manque de capacité mais bien la difficulté structurelle à propager un signal de gradient stable sur 20 pas de temps (la longueur maximale fixée pour ce jeu de données) – exactement le problème que les portes du LSTM et du GRU sont conçues pour atténuer.

Le GRU fait légèrement mieux que le LSTM ici (34,56 contre 37,30) avec environ 10% de paramètres en moins et un temps d'entraînement légèrement plus court. C'est un résultat cohérent avec la littérature, qui rapporte des performances souvent comparables entre LSTM et GRU sur des jeux de données de taille moyenne comme Multi30k, le GRU ayant l'avantage d'une cellule plus simple (deux portes au lieu de trois). Je nuancerais néanmoins cette conclusion : l'écart de 2,7 points de perplexité reste assez faible au regard de la variance que l'on observe typiquement entre deux exécutions d'un même modèle avec des graines aléatoires différentes ; une seule exécution par architecture ne permet pas d'affirmer avec certitude que le GRU est supérieur au LSTM dans l'absolu pour cette tâche.

5.4 Decodage glouton, beam search et BLEU

Le GRU, ayant la plus faible perplexité, a été retenu pour la phase de décodage. Deux stratégies ont été comparées : le décodage glouton (choix du mot le plus probable à chaque pas) et le beam search avec $k = 3$ hypothèses conservées en parallèle.

Modele	Parametres	Perplexite finale	Temps
RNN	3 025 800	153,84	323,6 s
LSTM	4 408 200	37,30	315,0 s
GRU	3 947 400	34,56	302,5 s

TABLE 5.2 – Comparaison des trois architectures recurrentes.




FIGURE 5.3 – Comparaison de la perplexite finale des trois architectures recurrentes.

Le gain du beam search (+0,029 de BLEU-1) est reel mais modeste, et porte sur seulement 5 exemples de validation – un echantillon trop petit pour generaliser ce chiffre au-dela de cette demonstration. Sur les exemples decodes ci-dessus (Figure 12), une limite plus visible que le score BLEU lui-meme est la repetition : plusieurs traductions generees contiennent des groupes de mots qui se repetent (par exemple des variations autour de *“ein Mann spielt Gitarre”*), un symptome typique d’un decodeur Seq2Seq sans mecanisme d’attention, qui doit compresser toute la phrase source dans un unique vecteur de contexte et perd donc progressivement l’information utile au fil de la generation.

5.5 Interpretation

Le RNN simple a une difficulte fondamentale a apprendre des dependances longues car toute l’information doit transiter par un unique etat cache mis a jour a chaque pas. LSTM et GRU introduisent des portes qui regulent explicitement ce qui doit etre oublie, mis a jour ou conserve, ce qui explique la chute spectaculaire de la perplexite par rapport au RNN simple. La limite commune aux trois, neanmoins, reste l’absence de mecanisme d’attention : le decodeur ne peut “revoir” la phrase source que via le vecteur de contexte fige produit par l’encodeur, ce qui explique a la fois les repetitions observees et le score BLEU encore modeste.

Modele utilise pour le decodage : GRU		
Source (EN)	Greedy	Beam Search k=3
a man is playing a guitar .	ein mann spielt gitarre und spielt gitarre ein anderer mann ein mann spielt gitarre	ein mann spielt gitarre
two dogs are running .	zwei hunde rennen über die wette zwischen zwei hunde zwei hunde rennen über die wette	zwei hunde rennen über die wette
a child is eating an apple .	ein kind isst einen kleinen gegenstand und isst ein kind isst einen kleinen gegenstand	ein kind isst einen kleinen gegenstand
a woman is reading a book .	eine frau liest ein buch liest ein buch liest zeitung eine frau liest ein buch liest	eine frau liest ein buch liest
a group of people are walking .	mehrere personen gehen hinter anderen personen eine gruppe von menschen geht zusam	eine gruppe von menschen geht zusam

FIGURE 5.4 – Exemples de decodage avec le modele GRU (greedy vs. beam search).

evaluation BLEU-1 sur les 5 premiers exemples de validation :		
Source (EN)	BLEU Greedy	BLEU Beam
A group of men are loading cotton ont	0.250	0.333
A man sleeping in a green room on a c	0.600	0.600
A boy wearing headphones sits on a wo	0.429	0.462
Two men setting up a blue ice fishing	0.200	0.231
A balding man wearing a red life jack	0.400	0.400
Moyenne	0.376	0.405
Perplexite finale par modele :		
RNN : PPL = 153.84		
LSTM : PPL = 37.30		
GRU : PPL = 34.56		

FIGURE 5.5 – Sortie brute de l'évaluation BLEU-1 sur les 5 premiers exemples de validation.

Strategie	BLEU-1 moyen	Interpretation
Greedy	0,376	Simple et rapide, mais localement optimal
Beam search $k = 3$	0,405	Meilleure exploration des hypotheses de traduction

TABLE 5.3 – BLEU-1 moyen selon la strategie de decodage (5 premiers exemples de validation).

Architecture	Force principale	Limite principale
RNN simple	Modele recurrent de base, simple a comprendre	Gradient instable et faible memoire longue
LSTM	Bonne gestion des dependances longues	Plus de parametres
GRU	Bon compromis simplicité/performance	Peut rester limite sans attention
Seq2Seq sans attention	Genere des sequences de longueur variable	Compression de toute la phrase dans un contexte unique

TABLE 5.4 – Synthese des architectures recurrentes testees.

6. Synthèse comparative des architectures

Aucune des trois architectures n'est universellement supérieure : chacune encode un biais inductif différent, adapté à une structure de données particulière.

Architecture	Données ciblées	Biais inductif	Performance	Limites
MLP	Tabulaire	Combinaisons non linéaires de variables	97,37% (Breast Cancer)	Surapprentissage, pas de structure spatiale
CNN	Images	Localité, partage des poids	79,94% (CIFAR-10)	Confusions sur classes proches
RNN	Séquences	État caché récurrent	PPL 153,84	Gradient instable
LSTM	Séquences longues	Cellule mémoire et portes	PPL 37,30	Complexité plus élevée
GRU	Séquences longues	Portes simplifiées	PPL 34,56	Limite sans attention

TABLE 6.1 – Synthèse comparative des cinq architectures testées.

Le MLP suffit pour une classification tabulaire binaire lorsque les variables sont déjà informatives et normalisées – le travail de représentation est en grande partie déjà fait avant même d'entrer dans le réseau. Le CNN devient indispensable dans le cas des images, où le travail de représentation (extraire des bords puis des formes puis des objets) doit être appris par le modèle lui-même ; lui imposer le bon biais inductif (localité, partage des poids) plutôt que de le laisser tout redécouvrir depuis un vecteur aplati change radicalement le résultat. Les architectures récurrentes, enfin, montrent que la capacité seule ne suffit pas : le RNN simple et le LSTM ont un nombre de paramètres du même ordre de grandeur, mais c'est la présence de portes – un mécanisme qualitativement différent, pas seulement plus de neurones – qui fait la différence.

7. Limites, ameliorations et perspectives

7.1 Limites observees

- Le MLP de la Partie I montre un debut de surapprentissage sur la validation apres une dizaine d'epoques, et le test d'initialisation en §3.4 n'a ete execute qu'une seule fois par configuration, ce qui en limite la portee statistique.
- Le CNN reste nettement plus faible sur les classes visuellement proches (*cat*, *dog*), avec une confusion asymetrique en faveur de *dog*.
- Le Seq2Seq recurrent sans attention produit des traductions parfois repetitives, un symptome direct de la compression de toute la phrase source dans un contexte unique.
- L'evaluation BLEU-1 n'a porte que sur 5 exemples de validation, ce qui est insuffisant pour generaliser la comparaison greedy/beam search au-dela de cette demonstration.

7.2 Ameliorations possibles

- Repeter l'entrainement du MLP avec plusieurs graines aleatoires et un early stopping explicite, pour verifier si l'ecart observe entre 97,37% et 98,25% (§3.4) tient ou disparaît une fois la variance moyennée.
- Tester des architectures CNN plus profondes ou residuelles (type ResNet) pour reduire specifiquement les confusions sur les classes *cat*/*dog*.
- Ajouter un mecanisme d'attention (Bahdanau ou Transformer) au systeme Seq2Seq pour attenuer les repetitions observees et ameliorer le BLEU au-dela de 0,405.
- Calculer le BLEU sur l'ensemble du jeu de validation, et non sur 5 exemples seulement, et comparer plusieurs largeurs de beam search ($k = 1, 3, 5, 10$).

7.3 Perspectives academiques

Ce projet constitue une base pour aborder des architectures plus recentes : CNN residuels, mecanismes d'attention, Transformers et apprentissage auto-supervise. Le point qui me semble le plus transferable d'une architecture a l'autre n'est pas une technique particuliere, mais une methode : verifier systematiquement, avant de choisir un modele, quelle structure (tabulaire, spatiale, sequentielle) porte réellement l'information utile dans les donnees.

8. Conclusion generale

Ce rapport a etudie trois familles de modeles de Deep Learning sur trois taches representatives. Le MLP a obtenu 97,37% d'accuracy test sur une classification tabulaire medicale, avec une reserve methodologique sur la comparaison des initialisations (§3.4). Le CNN a depasse de 34,84 points la baseline MLP sur CIFAR-10 (79,94% contre 45,10%) tout en utilisant environ 63% de parametres en moins, ce qui illustre concretement l'interet d'un biais inductif adapte aux images. Enfin, la comparaison RNN/LSTM/GRU a montre l'apport decisif des mecanismes de portes pour les sequences, le GRU obtenant la meilleure perplexite (34,56) avec le moins de parametres des deux architectures a portes, meme si cet ecart avec le LSTM reste a confirmer sur plusieurs executions.

Le fil conducteur des trois experimentations est le meme : un modele performant n'est pas necessairement le plus profond ou le plus parametre, mais celui dont les hypotheses structurelles correspondent le mieux a la nature des donnees traitees – absence de structure pour le MLP, structure spatiale locale pour le CNN, structure sequentielle avec memoire selective pour le GRU.

Bibliographie indicative

- Goodfellow, I., Bengio, Y., Courville, A. *Deep Learning*. MIT Press, 2016.
- LeCun, Y., Bottou, L., Bengio, Y., Haffner, P. *Gradient-based learning applied to document recognition*. Proceedings of the IEEE, 1998.
- Hochreiter, S., Schmidhuber, J. *Long Short-Term Memory*. Neural Computation, 1997.
- Cho, K. et al. *Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation*, 2014.
- Bahdanau, D., Cho, K., Bengio, Y. *Neural Machine Translation by Jointly Learning to Align and Translate*, 2015.
- Documentation PyTorch : modules `torch.nn`, `optim` et `DataLoader`.

Sources experimentales : les resultats, courbes et tableaux integres proviennent des trois notebooks du projet – Partie I (MLP), Partie II (CNN CIFAR-10) et Partie III (RNN/LSTM/GRU Seq2Seq).