

RAPPORT ACADEMIQUE DEEP LEARNING

Projet final integrateur
MLP - CNN - RNN/LSTM/GRU - Seq2Seq

Information	Valeur
Nom	Kenza Ezzahed
Filiere	AI & Data Science
Groupe	1
Site	Moulay Youssef
Ecole	EMSI Casablanca
Module	Deep Learning
Annee universitaire	2025-2026

Ce rapport presente les resultats experimentaux et leur analyse academique sans inclure le code source.

Remerciements

Je tiens à exprimer ma profonde gratitude à l'ensemble du corps professoral de l'EMSI Casablanca pour la qualité de la formation dispensée dans le domaine de l'intelligence artificielle et de la science des données.

Je remercie particulièrement l'enseignant du module Deep Learning pour l'encadrement, les orientations pédagogiques et les notions scientifiques transmises concernant les réseaux de neurones modernes.

Mes remerciements s'adressent également à ma famille et à mes proches pour leur soutien constant tout au long de cette formation.

Resume

Ce projet de Deep Learning explore trois familles d'architectures neuronales a travers des cas d'usage complementaires. La premiere partie traite la classification tabulaire du cancer du sein a l'aide d'un perceptron multicouche. La deuxieme partie applique des reseaux de neurones convolutifs a la reconnaissance d'images CIFAR-10. La troisieme partie etudie les architectures recurrentes RNN, LSTM et GRU dans un systeme Seq2Seq de traduction automatique anglais-allemand.

Les experimentations montrent que chaque architecture est adaptee a une nature de donnees particuliere : le MLP obtient de tres bons resultats sur des donnees tabulaires normalisees, le CNN surpasse nettement le MLP pour les images grace a l'exploitation de la structure spatiale, et le GRU offre le meilleur compromis pour la modelisation sequentielle dans le cadre de la traduction.

Mots-cles : Deep Learning, PyTorch, MLP, CNN, RNN, LSTM, GRU, Seq2Seq, CIFAR-10, Multi30k, classification, traduction automatique.

Abstract

This report studies three families of neural network architectures through complementary experiments. The first part focuses on tabular breast cancer classification using a multilayer perceptron. The second part applies convolutional neural networks to CIFAR-10 image recognition. The third part compares recurrent architectures, namely RNN, LSTM and GRU, within an English-to-German Seq2Seq translation system.

The results highlight the relevance of each model family according to the structure of the data. The MLP is efficient for tabular data, the CNN is significantly more suitable for images, and the GRU provides the best validation perplexity among the recurrent architectures tested.

Table des matieres

1. Introduction generale
2. Methodologie experimentale
3. Partie I - MLP pour la classification du cancer du sein
4. Partie II - CNN pour la vision par ordinateur sur CIFAR-10
5. Partie III - RNN, LSTM, GRU et Seq2Seq pour la traduction
6. Synthese comparative des architectures
7. Limites, ameliorations et perspectives
8. Conclusion generale
9. Bibliographie indicative

1. Introduction generale

Le Deep Learning constitue aujourd'hui une approche centrale de l'intelligence artificielle. Il permet d'apprendre automatiquement des representations pertinentes a partir de donnees variees : tableaux numeriques, images, textes ou sequences temporelles. L'objectif de ce projet est d'etudier plusieurs architectures fondamentales et de montrer dans quels contextes elles sont les plus pertinentes.

Le projet est structure en trois parties. La premiere partie porte sur un MLP applique a des donnees tabulaires medicales. La deuxieme partie aborde la vision par ordinateur avec un CNN sur CIFAR-10. La troisieme partie introduit les reseaux recurrents et un systeme encodeur-decodeur pour la traduction automatique.

Objectifs du projet

- Comprendre le fonctionnement d'un MLP, d'un CNN et d'un modele recurrent.
- Comparer les architectures selon la nature des donnees traitees.
- Analyser les courbes de perte, les performances finales et les erreurs de prediction.
- Justifier les choix d'architecture et proposer des ameliorations possibles.

Organisation du rapport

Chaque partie presente le contexte, les donnees, le modele, la strategie d'entrainement, les resultats experimentaux, puis une interpretation critique. Les captures integrees correspondent aux resultats produits durant l'execution des notebooks, en particulier les courbes de convergence et les tableaux de performance.

2. Methodologie experimentale

Les trois experimentations ont ete realisees avec PyTorch. Les donnees ont ete separees en ensembles d'entrainement, de validation et de test lorsque cela etait necessaire. Les modeles ont ete optimises avec une fonction de perte adaptee a la tache : cross-entropy pour la classification et cross-entropy masquee pour la generation de sequences.

L'evaluation repose sur des metriques specifiques : accuracy, precision, recall et F1-score pour la classification binaire ; accuracy et rapport de classification pour CIFAR-10 ; perplexite et BLEU-1 pour la traduction automatique.

Partie	Donnees	Architecture principale	Metriques
Partie I	Breast Cancer Wisconsin	MLP	Accuracy, precision, recall, F1-score
Partie II	CIFAR-10	CNN inspire de LeNet	Accuracy, F1-score, matrice de confusion
Partie III	Multi30k anglais-allemand	Seq2Seq avec RNN, LSTM et GRU	Perplexite, BLEU-1

La logique experimentale adoptee est la meme pour les trois parties : preparation des donnees, definition du modele, entrainement, sauvegarde ou selection du meilleur modele, evaluation finale et interpretation des resultats.

3. Partie I - MLP pour la classification du cancer du sein

3.1 Contexte et donnees

La premiere experimentation concerne une tache de classification binaire sur le jeu de donnees Breast Cancer Wisconsin. Les entrees sont des caracteristiques numeriques de cellules tumorales et la sortie correspond a l'une des deux classes medicales. Comme les variables sont continues et de dimensions comparables apres normalisation, un MLP constitue une architecture pertinente.

Element	Valeur retenue
Nombre total d observations	569
Nombre de caracteristiques	30
Entrainement	364 observations
Validation	91 observations
Test	114 observations
Type de tache	Classification binaire

3.2 Architecture et entraînement

Le modele utilise une entree de 30 variables, deux couches cachees de 64 et 32 neurones avec activation ReLU, puis une sortie a 2 classes. L'optimiseur Adam a ete utilise avec un taux d'apprentissage de 0,001 et la fonction de perte cross-entropy. L'entrainement a ete effectue pendant 50 epochs.

Parametre	Choix experimental
Taille d entree	30 variables numeriques
Couches cachees	64 neurones puis 32 neurones
Activation	ReLU
Sortie	2 classes
Optimiseur	Adam
Fonction de perte	Cross-entropy
Nombre d epochs	50

3.3 Resultats experimentaux

La courbe de perte montre une diminution rapide de la perte d'entraînement. La perte de validation baisse au debut, puis remonte progressivement, ce qui indique un debut de surapprentissage apres quelques epochs. Le meilleur modele est donc celui qui presente la meilleure performance sur validation, et non forcément celui de la derniere epoch.



Figure 1 - Courbe de perte du MLP : comparaison entre entraînement et validation.

L'accuracy de validation maximale obtenue est de 0,9670. Sur le jeu de test, le modele atteint une accuracy de 97,37 %, avec un F1-score proche de 97,87 %. Ces valeurs indiquent une tres bonne separation des deux classes sur ce jeu de donnees.

```
accuracy : 0.9736842105263158
precision : 0.9857142857142858
recall : 0.971830985915493
f1-score : 0.9787234042553191
```

```
matrice de confusion :
[[42  1]
 [ 2 69]]
```

Figure 2 - Capture des metriques finales du MLP et de la matrice de confusion.

Metrique	Valeur
Accuracy test	97,37 %
Precision	98,57 %
Recall	97,18 %
F1-score	97,87 %
Matrice de confusion	[[42, 1], [2, 69]]

3.4 Analyse de l'initialisation

Trois strategies d'initialisation ont ete comparees. Les resultats montrent que l'initialisation gaussienne obtient la meilleure accuracy dans cette experience, tandis que l'initialisation constante est moins robuste. Ce resultat confirme que l'initialisation influence la dynamique d'apprentissage et peut modifier la solution finale atteinte par l'optimisation.

gaussienne	accuracy: 0.9825 f1: 0.9859
constante	accuracy: 0.9474 f1: 0.9577
xavier	accuracy: 0.9649 f1: 0.9718

Figure 3 - Comparaison experimentale des initialisations du MLP.

Initialisation	Accuracy	F1-score	Interpretation
Gaussienne	98,25 %	98,59 %	Meilleur resultat observe
Constante	94,74 %	95,77 %	Moins efficace, risque de symetrie
Xavier	96,49 %	97,18 %	Stable mais legerement inferieure ici

3.5 Interpretation

Le MLP est adapte a ce probleme car les donnees sont tabulaires, normalisees et ne possedent ni structure spatiale ni structure temporelle. Les performances elevees montrent que les deux classes sont relativement separables. La remontee de la perte de validation rappelle toutefois l'importance de la regularisation, de l'early stopping et de la selection du meilleur modele.

4. Partie II - CNN pour la vision par ordinateur sur CIFAR-10

4.1 Contexte

La deuxième experimentation traite la classification d'images sur CIFAR-10. Ce jeu de données contient 10 classes d'objets, chaque image étant au format 32 x 32 en RGB. Contrairement aux données tabulaires, les images possèdent une structure spatiale forte : les pixels voisins sont corrélés et forment progressivement des bords, textures, formes et objets.

Un MLP appliqué directement à une image aplatie perd cette structure spatiale. Les CNN répondent à cette limite grâce à la localité des filtres, au partage des poids et à la construction hiérarchique des représentations.

Element	Valeur
Dataset	CIFAR-10
Nombre de classes	10
Format des images	32 x 32 RGB
Train	40 000 images
Validation	10 000 images
Test	10 000 images
Augmentation	Flip horizontal et recadrage aléatoire

Train : 40000 | Val : 10000 | Test : 10000



Figure 4 - Exemples d'images CIFAR-10 affichées après préparation des données.

4.2 Architecture CNN et baseline MLP

Une baseline MLP a d'abord été définie afin de mesurer la difficulté d'appliquer un réseau dense à des images aplaties. Le modèle CNN utilise ensuite trois blocs convolutifs avec normalisation de batch, activation ReLU et pooling. Une convolution 1 x 1 est employée comme mécanisme de réduction ou de transformation des canaux, puis un classificateur dense produit la classe finale.

Modele	Nombre de parametres	Principe
MLP baseline	1 707 274	Image aplatie en vecteur de 3 072 valeurs
CNN	624 970	Filtres locaux, pooling, extraction hiérarchique de features

Bien que le CNN possède moins de paramètres que la baseline MLP, il exploite beaucoup mieux la structure spatiale des images. Cette différence explique l'écart important observé dans les performances finales.

4.3 Courbes d'entraînement

Les courbes de la baseline MLP montrent une progression lente et une accuracy qui reste limitée. Cela confirme qu'un réseau dense n'est pas naturellement adapté aux images, car il traite les pixels comme des variables indépendantes.




Figure 5 - Courbes de perte et accuracy de la baseline MLP sur CIFAR-10.

Le CNN converge plus rapidement et atteint une accuracy de validation beaucoup plus elevee. La perte de validation diminue de maniere coherente avec la perte d'entrainement, ce qui indique une meilleure capacite de generalisation.




Figure 6 - Courbes de perte et accuracy du CNN sur CIFAR-10.

Modele	Accuracy test	Observation
MLP baseline	45,10 %	Performance limitee par la perte de structure spatiale
CNN	79,94 %	Net gain grace aux convolutions et au pooling

4.4 Evaluation finale

Le CNN atteint une accuracy de test de 79,94 %. Les classes les mieux reconnues sont notamment automobile, ship et truck, tandis que cat et dog restent plus difficiles en raison de similarités visuelles, de postures variées et d'un niveau de détail limité dans les images 32 x 32.

```

Test Accuracy – MLP : 45.10%
Test Accuracy – CNN : 79.94%

=== Classification Report (CNN) ===
              precision    recall  f1-score   support

   airplane      0.79      0.84      0.82     1000
  automobile      0.90      0.92      0.91     1000
     bird       0.72      0.69      0.70     1000
        cat      0.63      0.61      0.62     1000
       deer      0.77      0.78      0.78     1000
        dog      0.71      0.71      0.71     1000
       frog      0.80      0.88      0.84     1000
      horse      0.88      0.81      0.84     1000
        ship      0.90      0.89      0.90     1000
       truck      0.89      0.87      0.88     1000

 accuracy              0.80     10000
  macro avg              0.80      0.80      0.80     10000
 weighted avg              0.80      0.80      0.80     10000

```

Figure 7 - Rapport de classification du CNN sur le jeu de test CIFAR-10.

Classe	F1-score	Commentaire
automobile	0,91	Tres bonne reconnaissance
ship	0,90	Classe visuellement distinctive
truck	0,88	Bonne separation globale
cat	0,62	Classe la plus difficile
dog	0,71	Confusion frequente avec cat




Figure 8 - Matrice de confusion du CNN reconstituee a partir des resultats de test.

4.5 Interpretation

L'ecart entre le MLP et le CNN est significatif : le CNN augmente l'accuracy de test d'environ 34,84 points tout en utilisant environ 63 % de parametres en moins. Cela illustre l'interet fondamental des convolutions : elles imposent un biais inductif compatible avec les images, en apprenant des motifs locaux reutilisables dans toute l'image.

La matrice de confusion met en evidence les erreurs les plus importantes. Les confusions cat-dog et bird-deer-frog sont coherentes avec la nature de CIFAR-10, ou les images sont petites, parfois floues, et contiennent des objets dans des contextes varies.

Aspect	MLP	CNN
Representation	Vecteur aplati	Cartes de caracteristiques spatiales
Nombre de parametres	Plus eleve	Plus faible
Accuracy test	45,10 %	79,94 %
Generalisation	Limitee	Meilleure
Adaptation aux images	Faible	Forte

5. Partie III - RNN, LSTM, GRU et Seq2Seq

5.1 Contexte NLP


La troisieme experimentation porte sur la traduction automatique anglais-allemand avec Multi30k. Contrairement aux images, les phrases sont des sequences : l'ordre des mots et le contexte precedent influencent fortement le mot suivant. Les architectures recurrentes sont concues pour traiter ce type de dependance temporelle.

Un systeme Seq2Seq encodeur-decodeur a ete utilise. L'encodeur lit la phrase source et produit un etat de contexte. Le decodeur genere ensuite la phrase cible mot par mot. Trois cellules recurrentes ont ete comparees : RNN simple, LSTM et GRU.

Element	Valeur
Dataset	Multi30k anglais-allemand
Paires d entrainement	29 000
Paires de validation	1 014
Vocabulaire source	5 000 mots
Vocabulaire cible	5 000 mots
Longueur maximale	20 tokens
Embeddings	128 dimensions
Dimension cachee	256
Nombre de couches	2
Dropout	0,3

5.2 Problematique du gradient et clipping

L'entrainement des reseaux recurrents se fait par retropropagation a travers le temps. Lorsque les sequences sont longues, le gradient peut disparaître ou exploser. Le gradient clipping consiste a borner la norme du gradient afin d'eviter des mises a jour trop brutales.



Norme max sans clipping : 2.9300
Norme max avec clipping : 1.0000

Figure 9 - Effet du gradient clipping sur la norme du gradient.

La capture montre que la norme maximale sans clipping atteint 2,93, alors qu'elle est bornée à 1,00 avec clipping. Cette stabilisation est importante pour éviter des oscillations ou une divergence pendant l'entraînement.

5.3 Comparaison RNN, LSTM et GRU

Les trois architectures ont été entraînées pendant 15 epochs avec le même protocole. Le RNN simple présente une perplexité de validation très élevée et une courbe de validation instable. Le LSTM améliore fortement la performance grâce à ses portes de contrôle et à sa cellule mémoire. Le GRU obtient le meilleur résultat global dans cette expérience, avec une perplexité finale de 34,56.




Figure 10 - Courbes de perte RNN, LSTM et GRU.




Figure 11 - Comparaison de la perplexite finale des trois architectures recurrentes.

Modele	Parametres	Perplexite finale	Temps	Analyse
RNN	3 025 800	153,84	323,6 s	Instable et limite sur les dependances longues
LSTM	4 408 200	37,30	315,0 s	Forte amelioration grace aux portes
GRU	3 947 400	34,56	302,5 s	Meilleur compromis performance/complexite

5.4 Decodage glouton, beam search et BLEU

Après l'entraînement, le modèle retenu pour le decodage est le GRU car il obtient la plus faible perplexité. Deux stratégies de génération ont été comparées : le decodage glouton, qui choisit le mot le plus probable à chaque étape, et le beam search, qui conserve plusieurs hypothèses avant de choisir la meilleure séquence.

Modèle utilisé pour le decodage : GRU

Source (EN)	Greedy	Beam Search k=3
a man is playing a guitar .	ein mann spielt gitarre und spielt gitarre ein anderer mann ein mann spielt gitarre	ein mann spielt gitarre und spielt gitarre ein anderer mann ein mann spielt gitarre
two dogs are running .	zwei hunde rennen über die wette zwischen zwei hunde zwei hunde rennen über die we	zwei hunde rennen über die wette zwischen zwei hunde zwei hunde rennen über die we
a child is eating an apple .	ein kind isst einen kleinen gegenstand und isst ein kind isst einen kleinen gegens	ein kind isst einen kleinen gegenstand und isst ein kind isst einen kleinen gegens
a woman is reading a book .	eine frau liest ein buch liest ein buch liest zeitung eine frau liest ein buch lie	eine frau liest ein buch liest ein buch liest zeitung eine frau liest ein buch lie
a group of people are walking .	mehrere personen gehen hinter anderen personen eine gruppe von menschen geht zusam	mehrere personen gehen hinter anderen personen eine gruppe von menschen geht zusam

Figure 12 - Exemples de decodage avec le modèle GRU.

L'évaluation BLEU-1 sur les premiers exemples de validation donne une moyenne de 0,376 pour le decodage glouton et 0,405 pour le beam search. Le beam search améliore légèrement la qualité en explorant plusieurs chemins de génération.

évaluation BLEU-1 sur les 5 premiers exemples de validation :		
Source (EN)	BLEU Greedy	BLEU Beam
A group of men are loading cotton ont	0.250	0.333
A man sleeping in a green room on a c	0.600	0.600
A boy wearing headphones sits on a wo	0.429	0.462
Two men setting up a blue ice fishing	0.200	0.231
A balding man wearing a red life jack	0.400	0.400
Moyenne	0.376	0.405
Perplexité finale par modèle :		
RNN : PPL = 153.84		
LSTM : PPL = 37.30		
GRU : PPL = 34.56		

Figure 13 - Résultats BLEU-1 et perplexité finale par modèle.

Stratégie de decodage	BLEU-1 moyen	Interpretation
Greedy	0,376	Simple et rapide, mais localement optimal
Beam search k=3	0,405	Meilleure exploration des hypothèses de traduction

5.5 Interpretation

Le RNN simple a des difficultés à apprendre des dépendances longues car l'information doit être conservée uniquement dans un état caché récurrent. Le LSTM et le GRU introduisent des mécanismes de portes qui régulent l'oubli, la mise à jour et la conservation de l'information. Cela explique la forte réduction de la perplexité par rapport au RNN simple.

Malgré les améliorations, les traductions restent parfois répétitives. Cette limite est attendue pour un modèle Seq2Seq simple sans mécanisme d'attention. Une architecture avec attention, ou un Transformer, permettrait de mieux aligner les mots source et cible et d'améliorer la qualité globale de traduction.

Architecture	Force principale	Limite principale
RNN simple	Modèle récurrent de base, simple à comprendre	Gradient instable et faible mémoire longue
LSTM	Bonne gestion des dépendances longues	Plus de paramètres
GRU	Bon compromis entre simplicité et performance	Peut rester limité sans attention
Seq2Seq sans attention	Génère des séquences de longueur variable	Compression de toute la phrase dans un contexte unique

6. Synthèse comparative des architectures

Les trois parties montrent que le choix d'une architecture dépend fortement de la structure des données. Il n'existe pas une architecture universellement optimale : chaque famille de modèles possède un biais inductif spécifique.

Architecture	Données ciblées	Biais inductif	Performance observée	Limites
MLP	Données tabulaires	Combinaisons non linéaires de variables	97,37 % sur Breast Cancer	Risque de surapprentissage, pas de structure spatiale
CNN	Images	Localité et partage des poids	79,94 % sur CIFAR-10	Confusions sur classes proches, besoin de données
RNN	Séquences	État caché récurrent	PPL 153,84	Gradient instable
LSTM	Séquences longues	Cellule mémoire et portes	PPL 37,30	Complexité plus élevée
GRU	Séquences longues	Portes simplifiées	PPL 34,56	Limite sans attention

Lecture globale des résultats

Le MLP est suffisant pour une classification tabulaire binaire lorsque les variables sont informatives et correctement normalisées. Le CNN est indispensable pour exploiter la structure spatiale des images et réduire le nombre de paramètres. Les architectures récurrentes, quant à elles, sont adaptées aux séquences, mais les cellules à portes comme LSTM et GRU sont nécessaires pour améliorer la stabilité de l'apprentissage.

Le GRU ressort comme le meilleur modèle séquentiel dans ce projet, tandis que le CNN constitue le meilleur choix pour la vision par ordinateur. Ces conclusions sont cohérentes avec les principes théoriques des architectures et avec les courbes observées.

7. Limites, ameliorations et perspectives

7.1 Limites observees

- Le MLP presente un debut de surapprentissage sur la validation apres les premieres epochs.
- Le CNN reste limite sur les classes visuellement proches comme cat et dog.
- Le Seq2Seq recurrent sans attention produit parfois des traductions repetitives ou approximatives.
- Les resultats NLP ont ete evalues sur un nombre limite d'exemples pour le BLEU-1 simplifie.

7.2 Ameliorations possibles

- Ajouter de la regularisation et un early stopping plus strict pour le MLP.
- Tester des CNN plus profonds ou des architectures modernes comme ResNet pour CIFAR-10.
- Utiliser de l'attention ou un Transformer pour ameliorer la traduction automatique.
- Calculer BLEU sur un corpus complet et comparer plusieurs tailles de beam search.
- Realiser une recherche d'hyperparametres plus systematique.

7.3 Perspectives academiques

Ce projet constitue une base solide pour aller vers des architectures plus recentes : CNN residuels, mecanismes d'attention, Transformers et apprentissage auto-supervise. Il met en evidence l'importance de relier la nature des donnees, le choix du modele et les metriques d'evaluation.

8. Conclusion generale

Ce rapport a presente une etude experimentale de trois familles fondamentales du Deep Learning. Le MLP a montre son efficacite sur une classification tabulaire medicale, avec une accuracy test de 97,37 %. Le CNN a clairement surpasse la baseline MLP sur CIFAR-10, en atteignant 79,94 % d'accuracy test tout en utilisant moins de parametres. Enfin, la comparaison RNN, LSTM et GRU a montre l'interet des cellules a portes pour les sequences, le GRU obtenant la meilleure perplexite finale avec 34,56.

Les captures de courbes confirment les observations numeriques : la generalisation depend fortement de l'adequation entre l'architecture et la structure des donnees. Un modele performant n'est pas seulement un modele profond, mais un modele dont les hypotheses internes correspondent au probleme traite.

En conclusion, ce projet illustre les principes essentiels du Deep Learning applique : preparation des donnees, choix de l'architecture, analyse des courbes d'apprentissage, evaluation quantitative et interpretation critique des erreurs.

Fin du rapport

9. Bibliographie indicative

- Goodfellow, I., Bengio, Y., Courville, A. Deep Learning. MIT Press, 2016.
- LeCun, Y., Bottou, L., Bengio, Y., Haffner, P. Gradient-based learning applied to document recognition. Proceedings of the IEEE, 1998.
- Hochreiter, S., Schmidhuber, J. Long Short-Term Memory. Neural Computation, 1997.
- Cho, K. et al. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation, 2014.
- Bahdanau, D., Cho, K., Bengio, Y. Neural Machine Translation by Jointly Learning to Align and Translate, 2015.
- Documentation PyTorch : modules torch.nn, optimizers et DataLoader.

Sources experimentales

Les resultats, courbes et tableaux integres proviennent des trois notebooks fournis : Partie I MLP, Partie II CNN CIFAR-10 et Partie III RNN Seq2Seq.